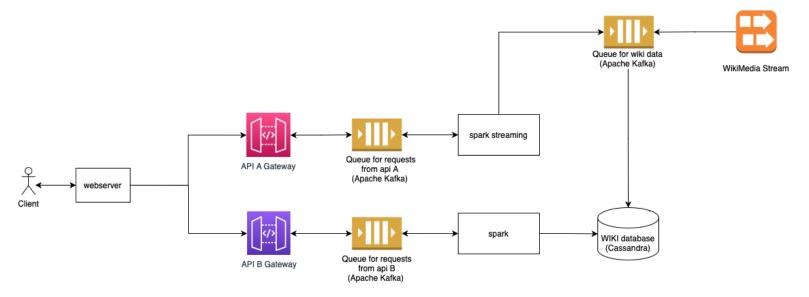
Wikimedia System Document

Detailed design documentation



Клієнт — користувач, який може взаємодіяти із системою.

Веб-сервер — єдиний спосіб взаємодії із системою через локальний порт браузера.

API A Gateway — веб сервер, який координує взаємодію клієнта з платформою. Усі запити, які надходять від клієнта і стосуються API A, йдуть через цей сервер. Реалізовано через <u>REST API</u>.

API B Gateway — веб сервер, який координує взаємодію клієнта з платформою. Усі запити, які надходять від клієнта і стосуються API В, йдуть через цей сервер. Реалізовано через <u>REST API</u>.

Є саме два "гейтвеї", оскільки вони реалізують окрему логіку над обробкою даних. Фактично, це не гейтвеї, а більше два окремих сервери, які обробляють окремі запити від клієнта і далі звертаються до різних компонент, які реалізовують логіку, потрібну для видачі результату саме для цього API.

Черга повідомлень для АРІ А — для зменшення навантаження на систему та забезпечення надійності, усі запити, що стосуються АРІ А, надсилаються у чергу повідомлень. При цьому в повідомленні вказується метод обробки даних для отримання результату, на який ϵ запит, і унікальне айді запиту. Черга ма ϵ два

топіки: request-topic і response-topic. Запити надсилаються у перший топік, результат читається із другого топіку. Реалізовано за допомогою <u>Kafka</u>.

Черга повідомлень для API В — аналогічно до попередньої черги, включно із функціоналом, топіками та інструментами для реалізації. Дві черги створено для ізоляції функціоналу одного API від іншого.

У цьому випадку, як варіант, можна було б створити, наприклад, 4 топіки (request-topic-A, response-topic-A, request-topic-B, response-topic-B), адже маємо усього два окремих API. Але в загальному, якби потрібно було додати нові ендпоінти чи реалізувати повністю нову логіку, створивши нові сервіси для API, наявність однієї черги для всіх уповільнила б роботу сервісів та викликала б непорозуміння в плані логічної ізоляції окремих компонент одна від одної.

Сервіс для стрімінгової обробки даних — реалізовано на основі <u>Spark Streaming</u>. Сервіс є основним "мозком" системи відносно API A, адже виконує всі обрахунки та операції над даними. Оскільки логіка API A така, що потрібно аналізувати дані за останні п годин, то вигідно брати дані як потік за потрібний час, а не піднімати всю датабазу для обрахунків. Тому цей сервер взаємодіє із двома чергами повідомлень: 1) для взаємодії із API A Gateway, читаючи запити та надсилаючи результат обробки даних; 2) для читання даних, які стрімом надходять із веб-серверу Wikimedia. Таким чином, ми забезпечуємо те, що будуть братися найбільш актуальні дані і швидкість обчислень буде більшою за рахунок того, що не будуть виконуватися запити безпосередньо до цілої датабази.

Черга для даних із Wikimedia — реалізовано на основі <u>Kafka</u>. Оскільки сайт оновлюється постійно, і дані надходять стрімом, ми не можемо записати все за один раз в датабазу. (Теоретично, можемо, але дані будуть доступні тільки до моменту, коли здійснений запис. Для отримання новіших даних потрібно буде знову звертатися на вебсайт і оновлювати дані. Можна було б реалізувати запис через кеш (in-memory БД Redis, наприклад), звертатися до вебсторінки раз на п секунд/хвилин/тощо, і перевіряти, чи не оновилися дані. Але обсяг даних на сторінці дуже великий, і кешувати їх всі — дуже неефективно і затратно в плані пам'яті). Тому дані потоком надходять у чергу повідомлень і поступово записуються в базу даних.

Сховище wiki даних — база даних на основі інструменту <u>Cassandra</u>. Оскільки об'єми даних великі, вони не структуровані та вимагають швидкого доступу до них, вибрано саме цей інструмент. У нашій системі немає вимог до consistency чи availability даних (мається на увазі, відсутній чіткий вибір між AP і CP), тому додаткових налаштувань Cassandra не має.

Сервіс для батч обробки даних — реалізовано на основі <u>Spark</u>. Сервіс ε основним "мозком" системи відносно API B, адже викону ε всі обрахунки та операції над даними (аналогічно до Сервісу стрімінгової обробки даних). Оскільки логіка API B така, що потрібно виконати аналіз даних за весь час, то використовуємо тут саме батч обробку даних, доступаючись до них безпосередньо через Cassandra. Сервіс взаємоді ε із чергою повідомлень для комунікації із API B Gateway, читаючи запити та надсилаючи необхідний результат.

WikiMedia stream — сторонній вебсайт (<u>за посиланням</u>), на якому відображаються дані у потоці, які нам треба обробити і використати.

Data models description

Дані медіа-потоку Wiki є великими та можуть включати велику кількість оновлень у реальному часі, редагувань та взаємодії з користувачем. Оскільки Cassandra має розподілену архітектуру, вона дозволяє масштабувати її горизонтально, додаючи більше вузлів до кластера. У результаті ми можемо працювати з високою пропускною здатністю запису та читання, що робить його придатним для зберігання та обслуговування швидкоплинних медіа-потоків.

3 огляду на те, які ендпоінти потрібно реалізувати в API обрані наступні таблиці з даними для збереження в сховищі з тих, що передаються медіа потоком Wiki:

1. Таблиця з композитним ключем з page_id та domain
Такий ключ потрібен для того, щоб мати змогу повернути список існуючих
доменів, для яких були створені сторінки та кількість сторінок, створених
для вказаного домену, оскільки в першому випадку звертатимуться по

```
page_id Та в другому по domain

(uid text,
domain text,
rev_timestamp text,
user_is_bot boolean,
user_id text,
PRIMARY KEY ((uid), domain))

uid-yhikaльний ключ для даних який береться з page_id

domain - домен Вікіпедії для даної сторінки
rev_timestamp - часова позначка для даної сторінки
user_is_bot - True, якщо користувач є роботом та False, якщо реальною
людиною
```

cqlsh:wiki> SELECT * FROM pages by domain;

uid	domain	rev_timestamp	user_id	user_is_bot
3953215	id.wikipedia.org	2023-06-08T08:09:58Z	1415671	True
4787929	ja.wikipedia.org	2023-06-08T08:10:07Z	1906552	True
9101936	mg.wiktionary.org	2023-06-08T08:10:08Z	380	True
73985218	en.wikipedia.org	2023-06-08T08:10:07Z	7701499	True
697993	sk.wikipedia.org	2023-06-08T08:10:02Z	236075	True
132785806	commons.wikimedia.org	2023-06-08T08:09:57Z	10101913	True
132785808	commons.wikimedia.org	2023-06-08T08:10:04Z	8873	True
113703004	www.wikidata.org	2023-06-08T08:10:04Z	588882	True
9101934	mg.wiktionary.org	2023-06-08T08:10:02Z	380	True
9101935	mg.wiktionary.org	2023-06-08T08:10:03Z	380	True
113703003	www.wikidata.org	2023-06-08T08:10:03Z	8461	True
1323171	mk.wikipedia.org	2023-06-08T08:10:08Z	31127	True
132785807	commons.wikimedia.org	2023-06-08T08:10:03Z	5142080	True

2. Таблиця з композитним ключем з page id ta user id

Такий ключ потрібен для того, щоб мати змогу повертати всі сторінки, створені користувачем із вказаним user id та сторінку з указаним

```
page_id
(uid text,
  domain text,
  rev_timestamp text,
  user_is_bot boolean,
  user_id text,
  PRIMARY KEY ((uid), user id))
```

Опис колонок аналогічний

3. Таблиця з композитним ключем з page id та rev timestamp

Такий ключ потрібен для того, щоб мати змогу повертати ідентифікатор, назву та кількість створених сторінок усіх користувачів, які створили принаймні одну сторінку за вказаний проміжок часу (власне

```
rev_timestamp).

(uid text,
  page_title text,
  rev_timestamp text,
  user_id text,
  PRIMARY KEY ((uid), rev_timestamp))

раде_title - назва сторінки
Решта колонок аналогічні
```